ESTOQUE INTELIGENTE

Protótipo de visão computacional para detecção de retirada e reposição de produtos em prateleiras

Jamilli Nilmara Gomes Monteiro | Judith Otavia Margarido de Andrade

1. Proposta original

Problema e relevância

Em pequenos estabelecimentos e ambientes de armazenamento, retiradas e reposições podem não ser registradas no momento em que ocorrem. Isso favorece atrasos, esquecimentos e divergências entre a quantidade física e os registros. O projeto investiga uma forma automatizada de acompanhar essas movimentações, gerar histórico e apoiar conferências posteriores. Os potenciais beneficiários são pequenos comerciantes, operadores de estoque e responsáveis pelo acompanhamento de produtos.

Solução proposta

Será desenvolvido um protótipo que recebe vídeos de uma prateleira, detecta um conjunto reduzido de produtos e analisa sua movimentação ao longo dos quadros. O objetivo não é classificar venda, perda ou furto, mas registrar evidências de entrada ou saída de produtos em uma área delimitada.

Elemento	Definição
Entrada	Vídeo gravado ou câmera fixa, cadastro de produtos e região monitorada.
Processamento	Detecção, associação temporal, análise espacial e validação do evento.
Saída	Produto, retirada, reposição ou inconclusivo, horário, histórico e alerta.

Justificativa da IA

Métodos tradicionais de diferença entre imagens podem indicar alteração na cena, mas tendem a confundir produtos com mãos, pessoas, sombras ou mudanças de iluminação. A IA será usada para localizar e classificar os produtos; a interpretação do evento combinará as detecções com associação temporal e regras espaciais.

Detecção por IA + associação temporal + regras de evento

Objetivo e MVP inicial

O objetivo geral é desenvolver e avaliar um protótipo acadêmico capaz de detectar produtos e registrar retiradas e reposições. O MVP utilizará uma câmera, uma prateleira, vídeos controlados e três a cinco classes visualmente distintas. Checkout autônomo, reconhecimento facial, identificação de furtos, múltiplas câmeras e integração completa com ERP ficam fora do semestre.

Uso da IA na ideação

A IA auxiliou a explorar a ideia, diferenciar detecção de produto de reconhecimento de evento e reduzir o escopo. Foram descartadas sugestões incompatíveis com o prazo, como múltiplas câmeras, grande catálogo, checkout autônomo e controle comercial completo.

2. Aprofundamento técnico

Problema e tarefa de IA

A pergunta refinada é: em que medida um detector adaptado com imagens do cenário experimental, combinado com associação temporal e análise de região, consegue reconhecer retirada e reposição de três a cinco classes em uma prateleira controlada? A tarefa envolve quatro níveis: localizar, classificar, associar detecções entre quadros e reconhecer o evento.

Dados

A investigação deverá considerar datasets públicos de detecção de objetos, conjuntos específicos de varejo e prateleiras e um dataset próprio. Dados públicos podem apoiar o pré-treinamento e a comparação, mas dificilmente reproduzirão a câmera, iluminação, embalagens e organização do experimento. Por isso, serão coletados vídeos próprios com retiradas, reposições, oclusões, cenas sem evento e movimentações que não representam retirada.

Aspecto	Decisão preliminar
Rótulos	Caixas delimitadoras e classes nas imagens; tipo e instante do evento nos vídeos.
Divisão	Treinamento, validação e teste separados por vídeo ou sessão.
Qualidade	Variar posição, quantidade, iluminação e oclusão; revisar anotações.
Privacidade	Ambiente controlado, sem reconhecimento facial ou áudio; retenção limitada.
Risco	Evitar quadros do mesmo vídeo em treino e teste para impedir vazamento.

Inteligência Artificial

A abordagem principal será um detector pré-treinado adaptado por transferência de aprendizado e fine-tuning com dados próprios. Não se prevê treinamento do zero. As detecções serão combinadas com associação temporal, região de interesse e regras para classificar retirada, reposição ou situação inconclusiva. A escolha final do modelo dependerá de licença, documentação, estabilidade, desempenho e compatibilidade com o hardware disponível.

Abordagem	Papel no experimento
Tradicional	Diferença entre quadros ou subtração de fundo como baseline.
Pré-treinada	Detector sem adaptação ao cenário como segunda referência.
Proposta	Detector ajustado com dados próprios e análise temporal.
Contingência	Monitoramento de posições fixas se a classificação não for confiável.

Trabalhos, ferramentas e soluções relacionadas

A revisão deverá abranger detecção de produtos, reconhecimento de embalagens, monitoramento de prateleiras, rastreamento de objetos e análise de eventos no varejo. Cada trabalho será comparado por problema, método, dataset, cenário, métricas, resultados e limitações. Soluções comerciais poderão demonstrar aplicabilidade, mas não substituirão artigos científicos e documentação oficial.

O diferencial proposto não é um novo algoritmo, mas a integração entre detecção, análise temporal e registro de movimentações em um protótipo acadêmico de baixo custo, delimitado para pequenos ambientes.

Requisitos computacionais

A preparação dos dados, API e interface podem ser desenvolvidas em computador convencional. O fine-tuning poderá exigir GPU, disponível localmente, em ambiente acadêmico ou serviço de notebook em nuvem. Modelos compactos serão priorizados se houver limitação computacional.

3. Desenvolvimento, avaliação e viabilidade

Arquitetura geral

Vídeo → preparação → detecção → associação temporal → análise da região → classificação do evento → registro → interface

O fluxo de treinamento será separado da execução: coleta e anotação, divisão dos dados, fine-tuning, validação e teste. Na inferência, o vídeo será processado pelo detector e pela lógica temporal antes de qualquer registro.

Menor protótipo funcional

- Cadastrar três a cinco produtos.
- Processar vídeo gravado de uma câmera fixa.
- Detectar e acompanhar os produtos ao longo dos quadros.
- Reconhecer retirada, reposição ou evento inconclusivo.
- Registrar produto, evento, quantidade estimada e horário.
- Apresentar histórico e alerta visual simples.

Avaliação e experimentos

A avaliação ocorrerá em três níveis. A detecção usará precisão, recall, F1-score, mAP e desempenho por classe. Os eventos usarão precisão, recall e F1 dos eventos, falsas retiradas, retiradas não detectadas e erro de contagem. O desempenho computacional considerará FPS e latência. As três abordagens serão executadas nos mesmos vídeos de teste, não utilizados no treinamento.

Comparação	Experimento
Baseline 1	Diferença entre quadros ou subtração de fundo.
Baseline 2	Detector pré-treinado sem adaptação.
Proposta	Detector adaptado e análise temporal.
Cenários	Retirada, reposição, oclusão, ausência de evento e movimentação sem retirada.

Riscos e alternativas

Risco	Alternativa
Produtos semelhantes	Começar com embalagens visualmente distintas.
Dados insuficientes	Ampliar gravações e usar transferência de aprendizado.
Oclusão	Persistência temporal e estado inconclusivo.
Falta de GPU	Modelo compacto e recurso acadêmico em nuvem.
Rastreamento instável	Simplificar associação, cena e posições.
Falsas retiradas	Exigir tempo mínimo antes da confirmação.
Atraso na integração	Priorizar o experimento antes do dashboard.

Viabilidade

O projeto é executável ao longo do semestre se permanecer limitado a uma câmera, uma área controlada, vídeos gravados e poucas classes. O maior risco é a qualidade dos dados próprios. Ainda será necessário obter ou confirmar os vídeos, ferramenta de anotação, GPU para treinamento e fontes acadêmicas. O processamento em tempo real será desejável, mas não obrigatório.

Critério de sucesso

O protótipo deverá funcionar de forma reproduzível, registrar eventos e apresentar desempenho superior a pelo menos um baseline. Os valores mínimos das métricas serão definidos após uma coleta piloto, evitando metas arbitrárias sem evidência experimental.

4. Uso da IA e proposta revisada

Uso da IA na investigação

Ferramentas de IA foram utilizadas para delimitar o problema, formular a pergunta de pesquisa, organizar o MVP, sugerir termos de busca, comparar abordagens, identificar riscos e estruturar a avaliação. As respostas da IA não serão usadas como referências acadêmicas; modelos, datasets, licenças e resultados deverão ser confirmados em fontes científicas ou oficiais.

Finalidade	Prompt principal

Viabilidade	Analise a viabilidade de visão computacional para identificar produtos retirados de uma prateleira.
Delimitação	Reduza a ideia para um protótipo de IA Aplicada executável em um semestre.
Dados	Quais dados e anotações são necessários para treinar e avaliar o sistema?
Modelos	Compare detecção, classificação e rastreamento para movimentações em vídeo.
Avaliação	Quais métricas avaliam separadamente detecção e eventos?
Riscos	Identifique riscos de uma câmera, uma prateleira e cinco classes.

Tratamento das sugestões

Sugestão da IA	Decisão
Dataset próprio e transferência de aprendizado	Aproveitada.
Comparação com método tradicional	Aproveitada como baseline.
Atualização automática do estoque comercial	Modificada para registro experimental.
Desaparecimento interpretado como retirada	Modificada para análise temporal e estado inconclusivo.
Múltiplas câmeras, furtos e checkout	Descartadas do MVP.
Processamento obrigatório em tempo real	Transformado em requisito opcional.

Proposta revisada

O Estoque Inteligente será um protótipo acadêmico de visão computacional para detectar produtos e reconhecer eventos de retirada e reposição em uma prateleira controlada. O problema investigado é a ausência ou o atraso no registro de movimentações físicas, que pode gerar divergências e demandar conferências manuais. A solução receberá vídeos de uma câmera fixa, detectará três a cinco classes e analisará as detecções ao longo do tempo. A saída será um registro contendo produto, tipo de evento, quantidade estimada, horário e confiança.

A abordagem principal utilizará um detector pré-treinado adaptado com dados próprios, associação temporal e regras de região. Serão coletados e anotados vídeos com retiradas, reposições, oclusões e cenas sem evento, com separação por sessão entre treinamento e teste. O protótipo incluirá persistência, histórico e alerta visual simples. Seu desempenho será comparado com diferença entre quadros e com um detector sem adaptação, utilizando métricas de detecção, eventos e latência.

A proposta é viável para um semestre porque limita ambiente, câmera, classes e funcionalidades. Os principais riscos são dados insuficientes, oclusão e produtos semelhantes; as alternativas incluem ampliar gravações, selecionar embalagens distintas, usar estado inconclusivo e reduzir o problema para posições fixas. O resultado esperado é demonstrar experimentalmente a viabilidade da abordagem, e não entregar um sistema comercial completo.

Referências

[1] GOLDMAN, Eran et al. *Precise Detection in Densely Packed Scenes*. In: IEEE/CVF Conference on Computer Vision and Pattern Recognition — CVPR, 2019. Trabalho que apresenta o dataset SKU-110K. Disponível em: CVF Open Access. Acesso em: 28 ago. 2026.

[2] WEI, Xiu-Shen; CUI, Quan; YANG, Lei; WANG, Peng; LIU, Lingqiao. *RPC: A Large-Scale Retail Product Checkout Dataset*. 2019. Disponível em: arXiv:1901.07249. Página oficial do dataset: RPC Dataset. Acesso em: 28 ago. 2026.

[3] MERLER, Michele; GALLEGUILLOS, Carolina; BELONGIE, Serge. *Recognizing Groceries in Situ Using In Vitro Training Data*. In: IEEE Conference on Computer Vision and Pattern Recognition — CVPR, 2007. Trabalho que apresenta o dataset GroZi-120. Disponível em: Columbia University. Acesso em: 28 ago. 2026.

[4] ZHANG, Yifu et al. *ByteTrack: Multi-Object Tracking by Associating Every Detection Box*. In: European Conference on Computer Vision — ECCV. Springer, 2022, p. 1–21. Disponível em: arXiv:2110.06864. Acesso em: 28 ago. 2026.

[5] YANG, Yanchao et al. *IncreACO: Incrementally Learned Automatic Check-Out With Photorealistic Exemplar Augmentation*. In: IEEE/CVF Winter Conference on Applications of Computer Vision — WACV, 2021. Disponível em: CVF Open Access. Acesso em: 28 ago. 2026.

[6] GUIMARÃES, Vinícius et al. *A Review of Recent Advances and Challenges in Grocery Product Recognition*. Applied Sciences, v. 13, n. 5, art. 2871, 2023. Disponível em: Applied Sciences. Acesso em: 28 ago. 2026.

[7] ULTRALYTICS. *Ultralytics YOLO Documentation*. Documentação oficial para detecção, treinamento, validação, rastreamento e exportação de modelos. Disponível em: Ultralytics Docs. Acesso em: 28 ago. 2026.

[8] PYTORCH. *TorchVision Object Detection Finetuning Tutorial*. Documentação oficial sobre adaptação de modelos pré-treinados para datasets próprios de detecção. Disponível em: PyTorch Tutorials. Acesso em: 28 ago. 2026.

[9] OPENCV. *OpenCV Documentation*. Documentação oficial da biblioteca de visão computacional e processamento de imagens e vídeos. Disponível em: OpenCV Documentation. Acesso em: 28 ago. 2026.

[10] CVAT. *CVAT Documentation: Annotation and Dataset Management*. Documentação oficial da ferramenta de anotação de imagens e vídeos. Disponível em: CVAT Documentation. Acesso em: 28 ago. 2026.

[11] BRASIL. *Lei nº 13.709, de 14 de agosto de 2018: Lei Geral de Proteção de Dados Pessoais — LGPD*. Brasília, DF: Presidência da República, 2018. Disponível em: Planalto — texto compilado da LGPD. Acesso em: 28 ago. 2026.

Para a versão de quatro páginas, as referências **[1] a [6]** sustentam a investigação acadêmica e os trabalhos relacionados; as referências **[7] a [10]** fundamentam as ferramentas e a implementação; e a referência **[11]** sustenta a seção de privacidade e proteção de dados.