ATIVIDADE 6 · SEGUNDA ENTREGA DO PROJETO

SmartStock Vision — da especificação à coleta de dados em execução

O que mudou desde a Atividade 5 (Marco 1 — Ideação e Marco 3 — Especificação técnica): a coleta de dados saiu do papel e está em execução real.

DISCIPLINA / TURMA
Laboratório de Inteligência Artificial — prof. Diego

GRUPO
Judith Otávia Margarido de Andrade

DATA
28 set. 2026

REPOSITÓRIOS
`smartstock-vision` · `estoque-inteligente`

> Na Atividade 5 (Marco 1 + Marco 3), a coleta de dados era só plano: o Marco 3 registrava explicitamente que o grupo tinha "menos de 10" fotos soltas, sem organização — "não constitui um dataset de treino ainda". Desde então, o grupo **implementou e colocou em execução** um pipeline automatizado de coleta, limpeza e aumento de dados, hoje rodando para as 5 classes do catálogo piloto, com meta fechada de 3.000 imagens balanceadas.

01 Recapitulação / 02 O que mudou / 03 Pipeline implementado / 04 Estado atual / 05 Especificação atualizada / 06 Próximos passos / 07 Uso de IA

01 Recapitulação — Atividade 5

A entrega anterior reuniu dois documentos:

- **Marco 1 (Ideação):** reconstruiu os dois pivôs do projeto — da ideia ampla de visão computacional (inventário + rastreamento + anti-furto) para um MVP focado, e depois do MVP dependente de um modelo treinado para uma arquitetura de *três fontes de detecção intercambiáveis* (`SIMULADO`, `SENSOR_PESO`, `CAMERA_REAL`), permitindo entregar cesta virtual, estoque e conferência de pagamento funcionando antes de existir qualquer modelo de IA treinado.
- **Marco 3 (Especificação técnica):** detalhou como a terceira fonte — `CAMERA_REAL` — seria implementada: classificação de imagem único-objeto via transfer learning (MobileNetV2/EfficientNet-B0), catálogo piloto de 8–12 produtos, plano de dados combinando datasets públicos (SKU-110K, RPC) com coleta própria por celular, metas de sucesso (≥92% top-1, F1 vs. baselines) e cronograma de 10 semanas.

Ponto de partida explícito do Marco 3, Seção 02: *"O grupo já tirou um pequeno lote de fotos de teste (menos de 10, ainda soltas e sem organização por produto) [...] não constitui um dataset de treino ainda."*

02 O que mudou: da coleta manual planejada à coleta automatizada em execução

O Marco 3 (Seção 09, "Riscos e plano B") já previa o risco **"poucas fotos por classe → overfitting"**, com o plano B **"augmentation agressiva + dataset público"**. Em vez de esperar a coleta manual por celular (mais lenta, sujeita a poucas dezenas de fotos por classe) para só depois recorrer a esse plano B, o grupo antecipou-o: implementou diretamente uma coleta automatizada por raspagem web, combinada com aumento de dados, para montar um dataset balanceado no volume-alvo.

ATIVIDADE 5 (PLANEJADO)

- < 10 fotos soltas, sem organização
- Coleta própria manual (celular), 60–100 fotos/produto
- 8–12 produtos genéricos do catálogo piloto
- Nenhum script de coleta implementado

ATIVIDADE 6 (EXECUTADO)

- Script de coleta funcionando (`gerar_dataset.py`)
- Coleta automatizada por raspagem web + augmentation
- 5 produtos reais definidos, com termos de busca próprios
- Meta fechada: 3.000 imagens balanceadas (600/classe)

03 Pipeline implementado

Repositório novo `estoque-inteligente` , script `gerar_dataset.py` . Quatro etapas, executadas em sequência:

ETAPA	COMO
Raspagem web	`icrawler` — Bing Image Search, com *fallback* automático para Google Imagens quando uma busca retorna zero resultados
Limpeza	Descarte de corrompidas, menore que 150px, e duplicatas por hash perceptual (`imagehash.phash`)
Split	Estratificado por classe, feito **ante** do augmentation (evita vazament treino↔teste)
Data augmentation	`Albumentations` — flip, rotação brilho/contraste, matiz/saturação, blur, ruído, recorte redimensionado

Classes do catálogo piloto (definidas nesta etapa)

CLASSE	TERMOS DE BUSCA USAD
`coca_cola_lata`	coca cola lata 350ml, coc gelada, coca cola lata pra
`fandangos_90g`	fandangos 90g, fandangc chips fandangos
`biscoito_oreo`	biscoito oreo pacote, ore 90g/original embalagem
`agua_mineral_500ml`	agua mineral 500ml garra agua mineral crystal 500r
`amendoim_japones`	amendoim japones paco peanuts package

Resultado final projetado: 5 classes × 600 imagens = **3.000 imagens** (2.100 treino / 600 validação / 300 teste) — dentro da meta

de 150–300 img/classe do Marco 3, com folga adicional para compensar ruído da coleta automática.

04 Estado atual da coleta

Execução em andamento no momento desta entrega. Captura do progresso da coleta bruta (antes da limpeza e do augmentation):

```
TERMINAL · ESTOQUE-INTELIGENTE/DATASET_BRUTO

dataset_bruto/biscoito_oreo/          36 arquivos
dataset_bruto/coca_cola_lata/         70 arquivos
dataset_bruto/fandangos_90g/          37 arquivos
dataset_bruto/agua_mineral_500ml/
(coleta ainda não iniciada)
dataset_bruto/amendoim_japones/
(coleta ainda não iniciada)
```

`em andamento` a coleta das 5 classes e a montagem final da pasta `dataset/` (treino/validação/teste + augmentation) serão concluídas antes da próxima etapa (fine-tuning). Este retrato documenta o estado real no momento da apresentação — não os números finais.

Amostra real de imagens coletadas (brutas, antes da limpeza)



coca_cola_lata



coca_cola_lata



biscoito_oreo



biscoito_oreo



fandangos_90g



fandangos_90g



amendoim_japones



amendoim_japones

Imagens brutas, direto da raspagem web, ainda sem a limpeza (dedup/filtro) nem o augmentation aplicados — por isso algumas trazem variações que não são o produto "ideal" (ex.: garrafa em vez de lata), exatamente o tipo de ruído de rótulo já documentado como risco na Seção 02 do Marco 3. A classe `agua_mineral_500ml` ainda não tem imagens coletadas no momento desta entrega.

05 Especificação técnica atualizada

A Seção 02 ("Dados") do documento de Marco 3 foi revisada para descrever o método de coleta efetivamente executado — raspagem web, limpeza por hash perceptual, split antes do augmentation, e aumento de dados via Albumentations — no lugar do plano original de coleta manual por celular. Os riscos de qualidade também foram atualizados: em vez de focar só em viés de ambiente de captura própria, agora cobrem ruído de rótulo em buscas de imagem, viés de "foto de catálogo" vs. prateleira real, e direitos de imagem de material raspado da web (uso restrito a fins acadêmicos).

Arquivo atualizado: `smartstock-vision-marco3.html` (mesmo repositório de especificação, Seções 02 e 10 revisadas nesta data).

06 Próximos passos

Concluir a coleta bruta

das 2 classes restantes (água mineral, amendoim japonês) e rodar a limpeza + augmentation completos, gerando a pasta `dataset/` final.

Revisão amostral manual

de uma fração das imagens brutas por classe, pra descartar falsos positivos da busca (produto errado, montagens, material sem o produto).

Baselines

(aleatório/majoritário e HOG+SVM), conforme já especificado no Marco 3, Seção 03.

Fine-tuning

do classificador principal (MobileNetV2 ou EfficientNet-B0) sobre o dataset final.

Avaliação

com as métricas e critérios de sucesso já definidos no Marco 3 (acurácia top-1/top-3, F1 vs. baseline, latência, robustez fora de distribuição).

07 Uso de IA nesta entrega

Ferramenta: Claude Code, usada para (a) ler o script de coleta já implementado e testado pelo grupo (`gerar_dataset.py`) e o estado real da pasta `dataset_bruto/` , (b) atualizar a Seção 02 do documento de Marco 3 para refletir o método de coleta efetivamente em uso, e (c) redigir este documento de segunda entrega a partir dessa leitura.

O que foi verificado diretamente antes de ser afirmado aqui: o conteúdo do script `gerar_dataset.py` (bibliotecas usadas, parâmetros de coleta/split/augmentation, lista de classes e termos de busca) e a contagem real de arquivos em cada pasta de `dataset_bruto/` no momento da redação — nada nas Seções 03/04 é extrapolado sem correspondência direta com o código e os dados existentes.

O que não foi alterado: o script de coleta em si não foi executado nem modificado por esta ferramenta — a coleta estava rodando em outra sessão de trabalho do grupo no momento desta entrega; apenas os números já produzidos até aqui foram lidos e reportados.