ATIVIDADE 9 · QUINTA ENTREGA

SmartStock Vision: o que evoluiu

Da raspagem da web ao dataset sintético feito com fotos próprias



Judith Otávia Margarido de Andrade

Laboratório de Inteligência Artificial · prof. Diego · 2026

ENTREGA ANTERIOR

Onde paramos

Coleta · raspagem web

Imagens da internet

icrawler (Bing/Google), 4 termos por produto, limpeza por pHash. Meta: 3.000 imagens, 600 por classe.

Modelo · planejado

Classificação por foto

Transfer learning (MobileNetV2 / EfficientNet-B0): um produto por imagem, rótulo = nome da pasta.

O ponto fraco

Os dados não eram da loja

“Lata” trouxe garrafa; “amendoim japonês” trouxe grão cru. Fotos de catálogo, com dono e sem caixas.

O QUE MUDOU · MUDANÇA DE ROTA

Da raspagem web ao dataset sintético

Aspecto	Entrega anterior	Agora
Origem dos dados	Imagens da web (catálogo)	**Fotos próprias dos produtos reais**
Tarefa do modelo	Classificação (1 produto por foto)	**Detecção YOLOv8**: vários produtos por cena
Rótulos	Nome da pasta, sem caixas	**Caixas geradas automaticamente**
Anotação	Roboflow, à mão	**Dispensada**
Volume	3.000 imagens (meta)	**4.200 cenas** + teste com fotos reais
Avaliação	Split antes do augmentation	**Split por foto de origem** + teste real

DISCUSSÕES E FEEDBACKS

O que ouvimos → o que fizemos

Tema	O que ouvimos	O que fizemos
Clareza	Prof. Diego: “ser mais claro, algo que dê para entender”	Uma ideia por slide, comparação antes × agora e o processo em etapas numeradas
Ruído de rótulo	Risco levantado na entrega anterior: “lata” trazia garrafa	Cada foto é tirada do produto certo: o rótulo é garantido na captura
Viés de catálogo	Fotos de estúdio não parecem a câmera da loja	Cenas com sombra, desfoque, tremido, ruído e fundos da loja
Direitos de imagem	Fotos da web têm dono	Dataset 100% com fotos próprias

NOVO · IMPLEMENTADO

Pipeline sintético: quatro etapas

01 · celular

Captura

30–40 fotos por produto, fundo liso, ângulos variados

→

02 · recortar.py

Recorte

Remove o fundo (cor ou rembg) e gera folha de revisão

→

03 · gerar_cenas.py

Composição

Prateleira, balcão e cesta; 1–8 produtos, distratores, oclusão

→

04 · câmera

Degradação

Luz, sombra, desfoque, tremido, ruído e JPEG

4.200	3.000	600	600
cenas com caixas YOLO	treino	validação	teste + fotos reais

NOVO · VALIDADE DA AVALIAÇÃO

Uma nota que não engana

Divisão · por foto de origem

Sem vazamento

Cada foto vai inteira para treino, validação ou teste. O teste usa também outros fundos.

test_real · a métrica que vale

Fotos reais nunca vistas

Fotos sem montagem, fora do treino: mede o desempenho no mundo real, não nas cenas.

Métricas · Marco 3

Como vamos medir

mAP@0,5 e mAP@0,5:0,95, F1, IoU e FPS. Base de comparação: YOLOv8 só com COCO.

ESTADO REAL · 20/10/2026

Ferramentas prontas; captura a iniciar

Implementado e versionado

- recortar.py (com folha de revisão)
- gerar_cenas.py (seed fixo, reprodutível)
- Notebook do Colab · Opção B (sem Roboflow)
- Guia de captura das fotos

Captura das fotos · não iniciada

- coca_cola_lata · 0 de 30
- biscoito_oreo · 0 de 30
- fandangos_90g · 0 de 30
- amendoim_japones · 0 de 30
- agua_mineral_500ml · 0 de 30

Limitação assumida: cenas montadas não têm reflexos e oclusões 100% físicos; por isso a conclusão usará o test_real.

SÍNTESE E PRÓXIMOS PASSOS

Mudança de rota: dados próprios, avaliação honesta

Entregue nesta etapa

- Gerador de dataset sintético
- Rótulos YOLO automáticos
- Split por foto de origem + test_real
- Notebook de treino atualizado

01 Fotografar as 5 classes, fundos da loja e distratores

02 Recortar e revisar os recortes

03 Gerar o dataset (4.200 cenas, seed fixo)

04 Fine-tuning do YOLOv8 no Colab (GPU T4)

05 Avaliar no test_real e comparar com o baseline COCO