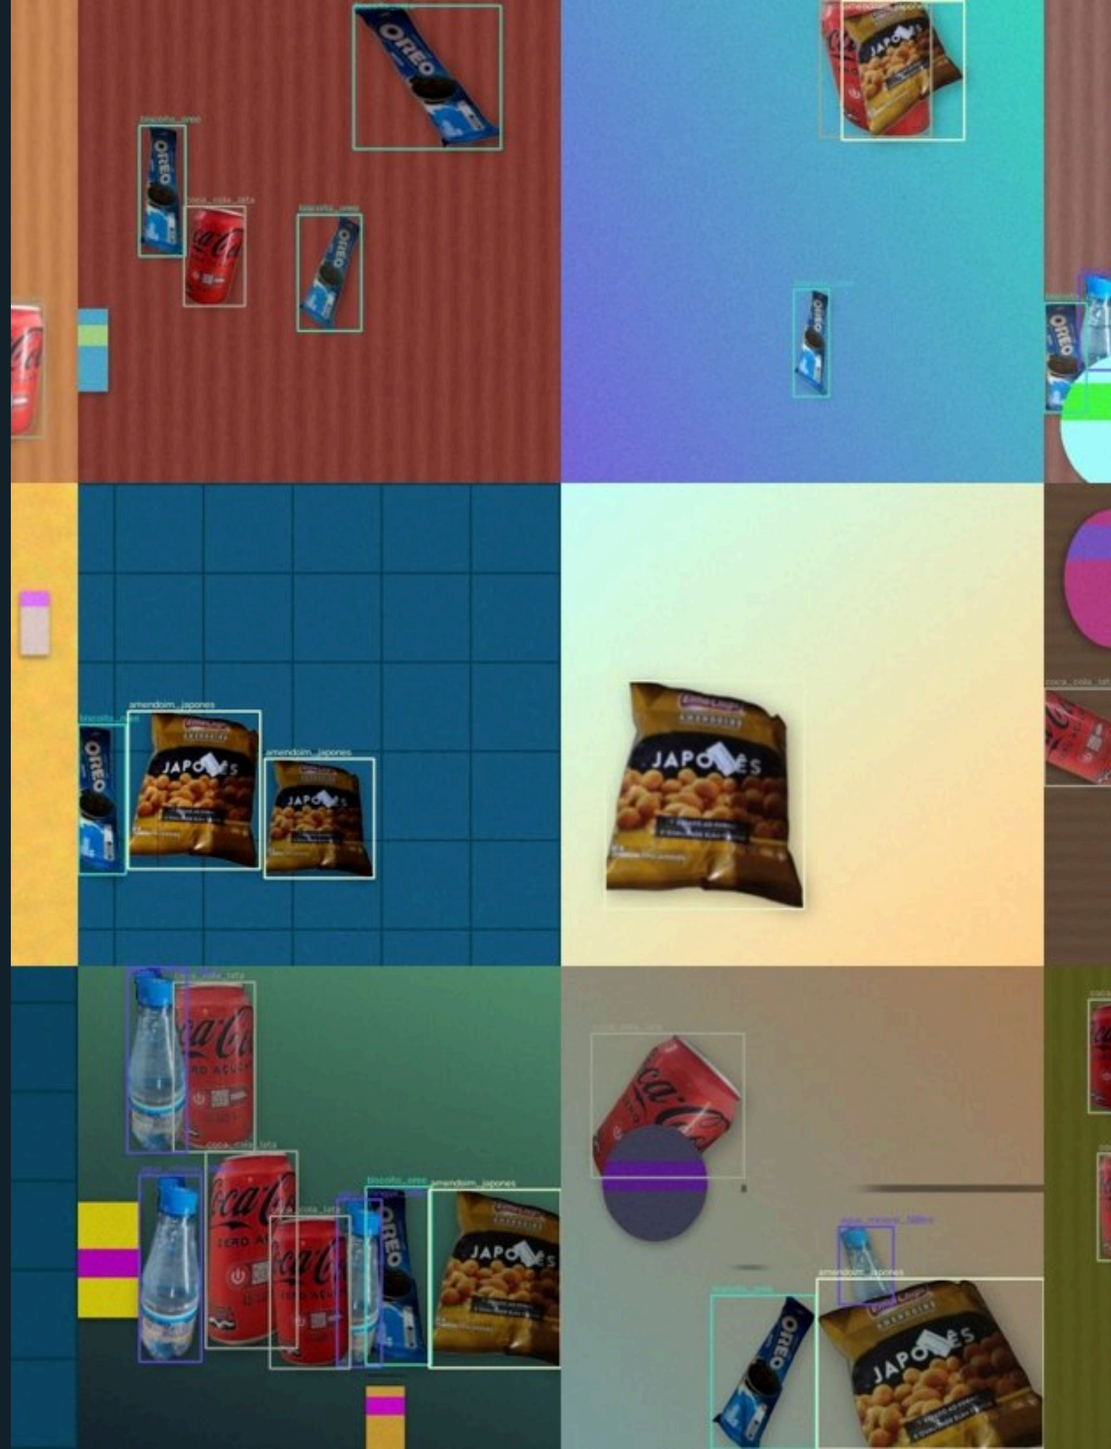
ATIVIDADE 11 · SÉTIMA ENTREGA

SmartStock Vision: a automação passo a passo

Da foto da loja ao YOLO treinando na GPU



Judith Otávia Margarido de Andrade

Laboratório de Inteligência Artificial · prof. Diego · 2026

O FLUXO AUTOMÁTICO

6 passos, quase tudo roda sozinho

1 `fotos`
fotos da loja (WhatsApp)
162

→

2 `rembg`
tira o fundo da foto
IA

→

3 `recortar.py`
recortes aprovados
11

→

4 `gerar_cenas.py`
cenas com caixas prontas
4.200

→

5 `Colab T4`
épocas de treino YOLOv8
50

→

6 `best.pt`
modelo treinado
✓



as fotos reais da loja que alimentam o fluxo

PASSOS 1 E 2 · rembg

A IA tira o fundo, fica só o produto



FOTO DA LOJA → SÓ O PRODUTO



FOTO DA LOJA → SÓ O PRODUTO

python recortar.py --rembg · 20 recortes feitos, 9 descartados por defeito

PASSOS 3 E 4 · gerar_cenas.py

Recortes viram cenas com caixa automática



os 11 recortes aprovados

→



3.000 treino | 600 validação | 600 teste

PASSO 5 · TREINO CONCLUÍDO

50 épocas na GPU, 36 minutos

```
Epoch    GPU_mem   box_loss   cls_loss   dfl_loss  Instances       Size
 1/50      2.08G     0.6357       1.15       1.03         54        640: 100% ━━━━━━━━━━━━ 188/188 4.4it/s 42.6s
           Class     Images  Instances      Box(P          R      mAP50  mAP50-95): 100% ━━━━━━━━━━━━ 19/19 3.6it/s 5.2s
             all        600       2678      0.948      0.937      0.982      0.874

Epoch    GPU_mem   box_loss   cls_loss   dfl_loss  Instances       Size
 2/50      2.63G     0.5797      0.538     0.9837         33        640: 100% ━━━━━━━━━━━━ 188/188 4.9it/s 38.2s
           Class     Images  Instances      Box(P          R      mAP50  mAP50-95): 100% ━━━━━━━━━━━━ 19/19 3.2it/s 5.9s
             all        600       2678       0.97      0.938      0.986      0.869

Epoch    GPU_mem   box_loss   cls_loss   dfl_loss  Instances       Size
 3/50      2.63G     0.5799     0.5067     0.9845         60        640: 100% ━━━━━━━━━━━━ 188/188 5.1it/s 36.7s
           Class     Images  Instances      Box(P          R      mAP50  mAP50-95): 100% ━━━━━━━━━━━━ 19/19 3.2it/s 5.8s
             all        600       2678      0.941      0.911      0.974      0.825

Epoch    GPU_mem   box_loss   cls_loss   dfl_loss  Instances       Size
 4/50      2.63G     0.5659     0.4882     0.9765         59        640: 100% ━━━━━━━━━━━━ 188/188 5.1it/s 37.0s
           Class     Images  Instances      Box(P          R      mAP50  mAP50-95): 100% ━━━━━━━━━━━━ 19/19 3.5it/s 5.4s
             all        600       2678      0.941      0.931      0.977      0.841
```

época 1 a 4

```
Epoch    GPU_mem   box_loss   cls_loss   dfl_loss  Instances       Size
50/50      2.63G     0.2131     0.1689     0.8155         31        640: 100% ━━━━━━━━━━━━ 188/188 5.5it/s 34.2s
           Class     Images  Instances      Box(P          R      mAP50  mAP50-95): 100% ━━━━━━━━━━━━ 19/19 3.3it/s 5.7s
             all        600       2678      0.975      0.974      0.992      0.927

50 epochs completed in 0.597 hours.
Optimizer stripped from /content/runs/detect/smartstock_vision/weights/last.pt, 6.5MB
Optimizer stripped from /content/runs/detect/smartstock_vision/weights/best.pt, 6.5MB
```

época 50: treino concluído (50 epochs completed in 0.597 hours)

36 min
50 épocas na GPU T4

1,15 → 0,17
erro de classe (cls_loss), época 1 → 50

mAP50 0,992
precisão 0,975 · recall 0,974
nas 600 cenas de validação (sintéticas)

PASSO 7 · AVALIAÇÃO

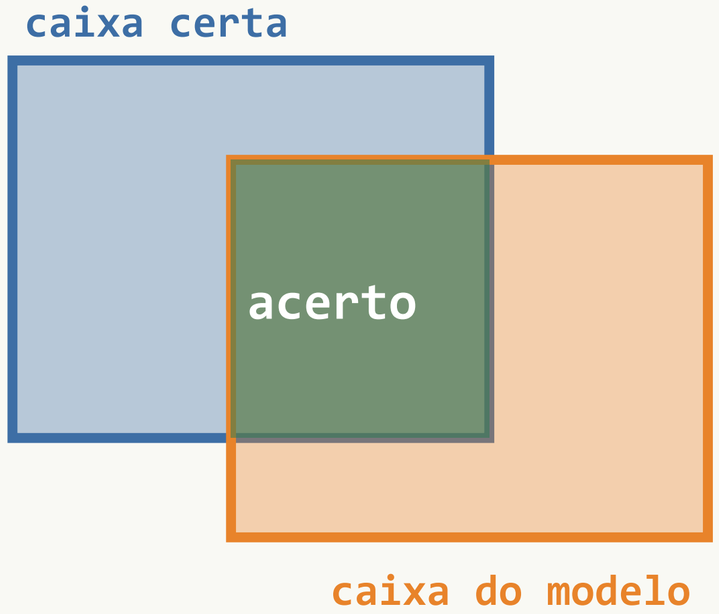
Como saber se o modelo acertou?

```
metricas = modelo.val()

precisao = metricas.box.mp       # precisão média
revocacao = metricas.box.mr      # recall médio
f1 = 2 * precisao * revocacao / (precisao + revocacao) if (precisao + revocacao) > 0
else 0

print(f'Precisão média: {precisao:.3f}')
print(f'Recall médio: {revocacao:.3f}')
print(f'F1-score: {f1:.3f}   (meta definida no plano: >= 0.40)')
print(f'mAP@50: {metricas.box.map50:.3f}')
print(f'mAP@50-95: {metricas.box.map:.3f}')
```

o código do Passo 7 do caderno: o Colab calcula as notas sozinho



IoU = área da sobreposição ÷ área das duas caixas juntas. Acima de 0,5 conta como acerto.

Precisão

dos que ele marcou, quantos estavam certos

Recall

dos produtos que existem, quantos ele achou

F1

a média das duas
meta do plano: ≥ 0,40

mAP@50

nota média das 4 classes usando IoU ≥ 0,5

PASSO 7 · RESULTADO

As notas do modelo na validação

```
                 Class     Images  Instances      Box(P          R      mAP50  mAP50-95): 100% ━━━━━━━━━━━━ 38/38 4.9it/s 7.8s
                   all        600       2678       0.97      0.979      0.993      0.938
     agua_mineral_500ml        528       1336      0.966      0.989      0.994      0.964
         coca_cola_lata        525       1342      0.975       0.97      0.993      0.912
Speed: 1.5ms preprocess, 4.8ms inference, 0.0ms loss, 2.0ms postprocess per image
Results saved to /content/runs/detect/val
Precisão média: 0.970
Recall médio: 0.979
F1-score: 0.975   (meta definida no plano: >= 0.40)
mAP@50: 0.993
mAP@50-95: 0.938
```

0,970
precisão

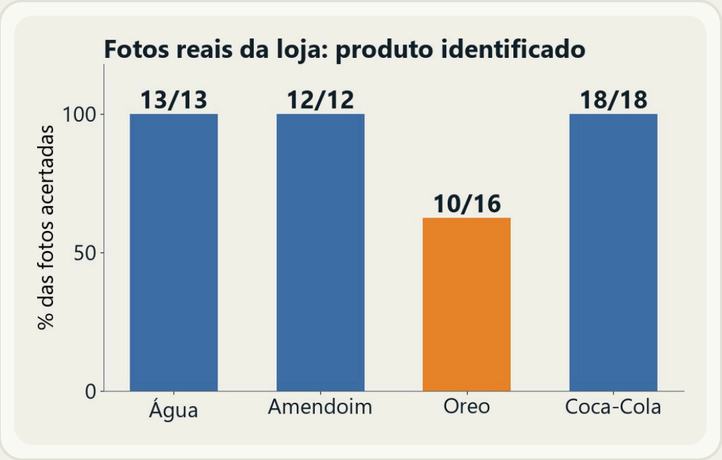
0,979
recall

0,975
F1 · meta do plano ≥ 0,40

0,993
mAP@50

Atenção: a validação só tem água e Coca-Cola. Amendoim e Oreo (1 e 2 recortes) ficaram só no treino, então a nota vale para 2 dos 4 produtos, em cenas sintéticas.

E nas fotos de verdade da loja?





amendoim ✓



coca ✓



oreo ✓



oreo ✗ errou

53 de 59 fotos identificadas (90%)

best.pt salvo · 6,5 MB

teste rápido, ainda sem rótulos

Caixas com confiança acima de 50% (na foto do erro, a partir de 25%). Acerto = o produto de maior confiança é o da foto.

PRÓXIMOS PASSOS

O que falta para fechar o ciclo

01 Rotular as 59 fotos reais (nota oficial, com mAP)

02 Corrigir o Oreo: mais recortes e fotos

03 Medir F1 e mAP nas fotos reais

04 Fotos do Fandangos (5º produto)

05 Comparar com o YOLO sem treino



cenas de validação = fáceis. A nota que vale vem das fotos reais.